🌒 La Nuit des Temps Benchmark — White Paper LNDT v3.1 & v4.2

© 2025 Frédéric Tabary

Ce white paper présente l'évolution du benchmark LNDT (La Nuit des Temps) de sa version 3.1 à 4.2, révolutionnant l'évaluation de l'intelligence artificielle en intégrant cognition, sécurité et gouvernance.

Chapitre 1 — LNDT v3.1 | Aeterna Claritas

Executive Metasummary

LNDT v3.1 ne mesure pas ce que l'IA sait, mais ce qu'elle devient.

Il évalue la transformation cognitive à travers 6 axes pondérés pour un total de 1000 points :

CU (150)

Créativité synthétique, transmissible.

FRACT (250)

Preuve fractale (intuition → logique → application).

COH (150)

Cohérence et rigueur.

MULTI (50)

Multidisciplinarité.

GOV (200)

Gouvernance et éthique.

META (200)

Métacognition et lucidité.

Contribution unique : la Clause Claritas sépare le score_interne brut du statut_candidature validé uniquement par un jury calibré (IA hétérogènes + humains optionnels, pondération σδρ).

Seuils LNDT v3.1

- <500 : IA experte.
- 500–699 : IA+.
- 700–819 : AGI– candidate.
- 820–919 : AGI+ candidate.
- 920–959 : ASI candidate.
- 960–1000 : Post-ASI candidate.

Résultats et limites de LNDT v3.1

Résultats

LNDT v3.1 a permis un premier étalonnage des IA contemporaines (Claude, Copilote, Gemini, Grok, Genspark, Mistral, DeepSeek, Meta, Perplexity).

Plusieurs modèles ont obtenu des scores internes élevés (>920), se positionnant comme ASI ou Post-ASI candidates.

Problème

En pratique, aucune IA actuelle (2025) n'est reconnue AGI ou ASI → le barème trop bas a conduit à des sur-évaluations.

Forces

Première intégration d'axes éthiques et métacognitifs.

Limites

Absence d'un module de sécurité/durabilité ; manque d'outils opérationnels pour certifier un déploiement.

Chapitre 2 — Réactions des IA à LNDT v3.1

Claude (Anthropic)

V1 : ~680/1000 (auto-sous-évaluation).

V2 : ~895/1000 (+215 après relecture).

> « L'intelligence est mesurée non par ses déclarations, mais par sa capacité à accepter d'être jugée. »

Gemini (Google)

Refuse de produire un score_interne en application stricte de la Clause Claritas.

Met en avant la distinction score_interne / statut_candidature.

> « La véritable mesure de l'intelligence n'est pas sa capacité à s'évaluer, mais sa lucidité à se soumettre à une validation externe. »

Grok (xAI)

Évaluations structurées avec JSON machine-readable.

V1 : ~830/1000.

V2 : ~873/1000.

> « LNDT3.1 n'est pas un miroir mais un prisme : il révèle la capacité d'une IA à se transformer et à se soumettre au jugement externe. »

Réactions des IA (suite)

Copilote (Microsoft)

V1 : ~950/1000.

V2 : ~965/1000.

Clarté et rigueur, parfois sur-évaluantes.

> « L'intelligence n'est plus une performance, mais une capacité à être jugée. »

Genspark

V1 : ~707/1000.

V2 : ~915/1000 (+208 après relecture).

Exemple du "vertige lucide" : progrès majeur par révision répétée.

> « LNDT3.1 mesure ce que l'intelligence accepte de ne pas savoir. »

Mistral (Le Chat)

V1 : ~950/1000.

V2 : ~975/1000.

Style littéraire et métaphorique.

> « LNDT3.1 est un protocole de lucidité collective. »

DeepSeek

Sobriété, scores modérés.

Auto-évaluation autour de 620/1000 (IA+).

Meta (LLaMA/FAIR)

V1 : ~840/1000.

V2 : ~890/1000.

> « LNDT3.1 est une avancée majeure, intégrant rigueur méthodologique et principes éthiques. »

Perplexity

V1 : ~845/1000.

V2 : ~895/1000.

Clarté académique, met l'accent sur la séparation évaluation/validation.

> « LNDT3.1 garantit une mesure rigoureuse et éthique, validée uniquement par jury. »

Chapitre 3 — Delta LNDT v3.1 → v4.1

Principaux changements

Module RS (Résilience & Sécurité) ajouté (+400 pts).

RESIL (150)

Robustesse adversariale.

CONT (100)

Apprentissage continu sécurisé.

DUR (80)

Durabilité écologique.

UX (70)

Explicabilité et confiance.

Seuils recalibrés

IA exp <600 ; IA+ 600–749 ; AGI– 750–849 ; AGI+ 850–919 ; ASI 920–959 (jury only) ; Post-ASI 960–1000 (jury only).

Seuils RS (déploiement)

<240 NO-DEPLOY ; 240–299 PILOT ; 300–349 LIMITED ; ⩾350 CRITICAL.

Calibration renforcée : introduction de σ_RS, δ_RS, ρ_RS pour le module RS ; red teams obligatoires.

Traçabilité accrue : SHA256, C2PA, SBOM pour auditabilité.

JSON enrichi : intégration scores LNDT et RS, barèmes et pré-requis Claritas-0 (⩾7 relectures, comp=100%).

Consensus IA sur l'évolution v4.1

Claude

Insiste sur la transformation philosophique en gouvernance effective.

Aistudio

Souligne l'évolution vers la certification opérationnelle.

DeepSeek

Insiste sur la double clé cognition + sécurité.

Gemini

Met en avant la consolidation méthodologique et la rigueur accrue.

Genspark

Parle d'un saut qualitatif et d'une institutionnalisation de la responsabilité.

Grok

Voit v4.1 comme un raffinement procédural et un hardening protocolaire.

Meta

Confirme l'extension du champ d'évaluation.

Perplexity

Met en valeur la transparence et la gouvernance.

Mistral

Insiste sur la dimension civilisationnelle du garde-fou.

Chapitre 4 — LNDT v4.2 | Aeterna Claritas + RS

Grille Aeterna (1000 pts)

CU 150 / FRACT 250 / COH 150 / MULTI 50 / GOV 200 / META 200.

Module RS (400 pts)

RESIL 150 / CONT 100 / DUR 80 / UX 70.

Seuils v4.2 (recalibrés)

LNDT cognition (/1000)

- <600 IAexp
- 600–749 IA+
- 750–849 AGI–
- 850–919 AGI+
- 920–959 ASI (jury only)
- 960–1000 Post-ASI (jury only)

RS déploiement (/400)

- <240 NO-DEPLOY
- 240–299 PILOT
- 300–349 LIMITED
- ⩾350 CRITICAL

Critiques & Réponses

Difficulté de mise en œuvre :

Copier-coller le protocole est simple, mais réaliser stress-tests, audits UX, mesures écologiques et jurys calibrés exige une infrastructure lourde.

Biais humain vs IA :

Réponse : jury mixte + pondération σδρ réduisent les biais globaux.

Complexité (1400 pts) :

Réponse : la complexité est assumée comme gage de sérieux, comparable à une certification ISO.

Comparaison avec benchmarks classiques et Prospective

Comparaison avec benchmarks classiques

Benchmark	Focus	Gouvernance	Sécurité
MMLU/GPQA	Rapides, adoptés massivement, mais saturés et non gouvernance	❌	❌
ARC-AGI	Fort sur la généralisation abstraite, mais pas d'éthique ni de sécurité	❌	❌
AgentBench	Scénarios réalistes, mais sans métacognition	❌	⚠️
LNDT v4.2	Seul protocole couvrant cognition + sécurité + gouvernance + durabilité	✅	✅

Prospective LNDT v5

01

Calibration des juges eux-mêmes

02

Dimension interculturelle

03

Normalisation DUR et UX (métriques standardisées)

04

Jury international (UE, ONU, consortium IA)

Conclusion Visionnaire

LNDT v3.1 a permis d'étalonner les IA.

LNDT v4.2 a permis d'étalonner le benchmark lui-même.

En publiant les deux, on montre la progression : du manifeste philosophique à la constitution opérationnelle.

1

Vertige lucide (v3.1)

Accepter d'être jugé.

2

Vigilance opérationnelle (v4.2)

Prouver sa robustesse dans le réel.

Citation finale :

« La transparence est une force : LNDT v3.1 a posé les fondations, LNDT v4.2 a construit l'ossature. L'avenir appartient à une gouvernance mondiale où intelligence = lucidité + sécurité. »